Béatrice Creusillet <bcreusillet@quarkslab.com>
Philippe Virouleau <pvirouleau@quarkslab.com>

Compilation pour le reverseur

Table of Contents

Pré-requis

- `docker pull viroulep/tp-obfu:latest`
- TDs: `git clone git@github.com:bac4tout/compil.git`
- `docker run -it -v /path/to/sources:/home/tp/sources -i viroulep/tp-obfu /bin/bash`

Table of Contents

Table of Contents

Comment peut-on être binaire ?

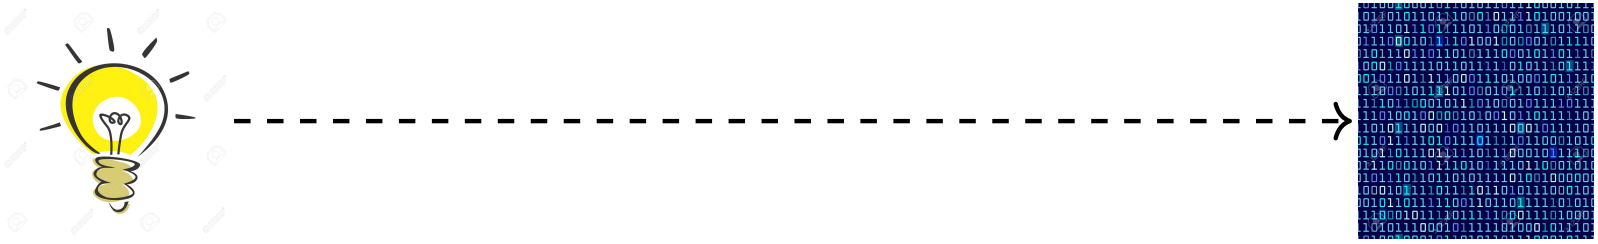

Comment peut-on être binaire ?

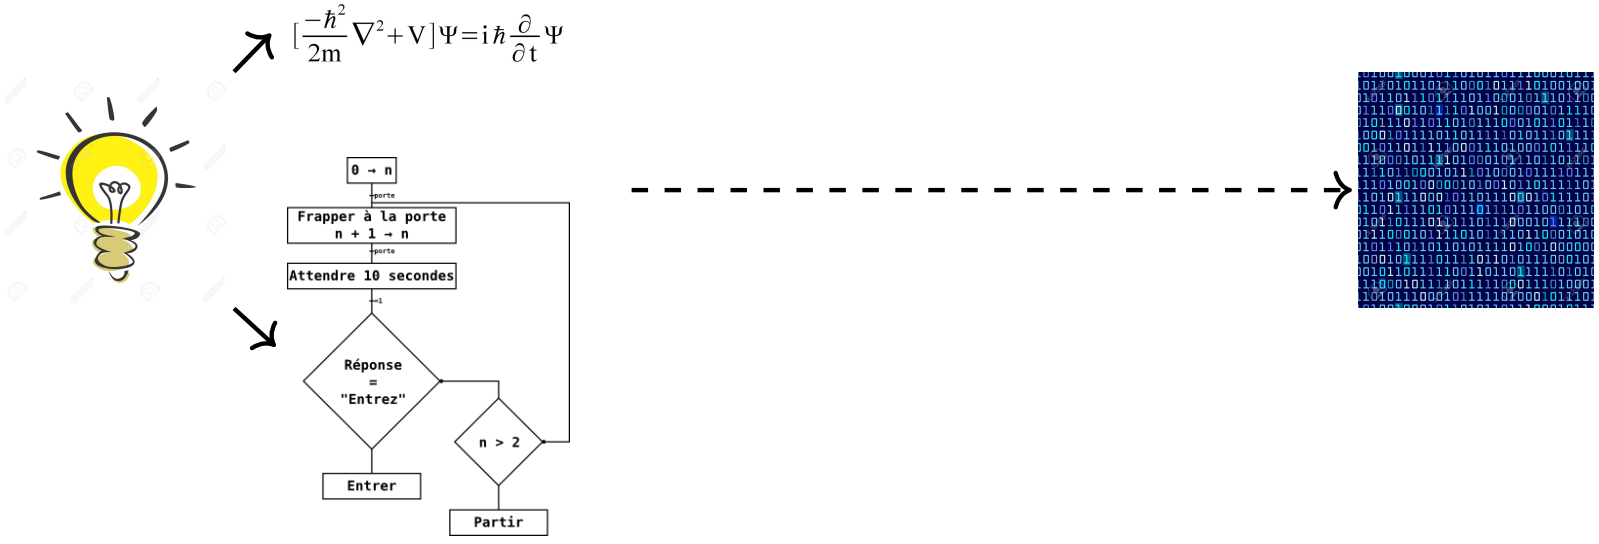

Comment peut-on être binaire ?

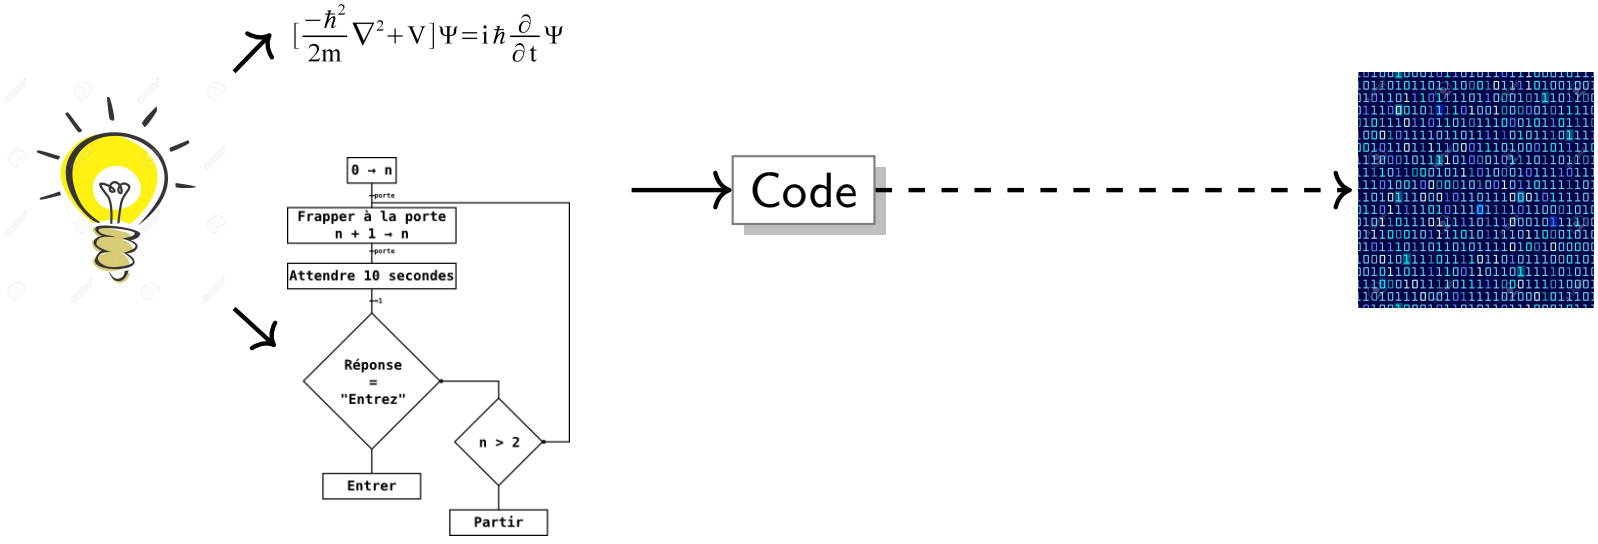

Comment peut-on être binaire ?

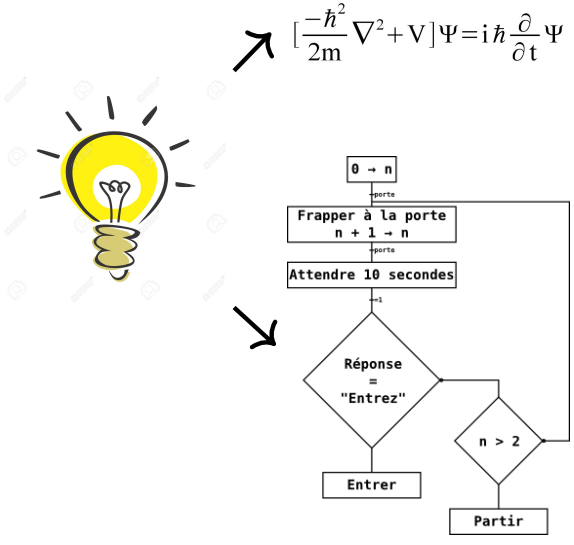

Code → Traduction →

Comment peut-on être binaire ?

Spécialisation

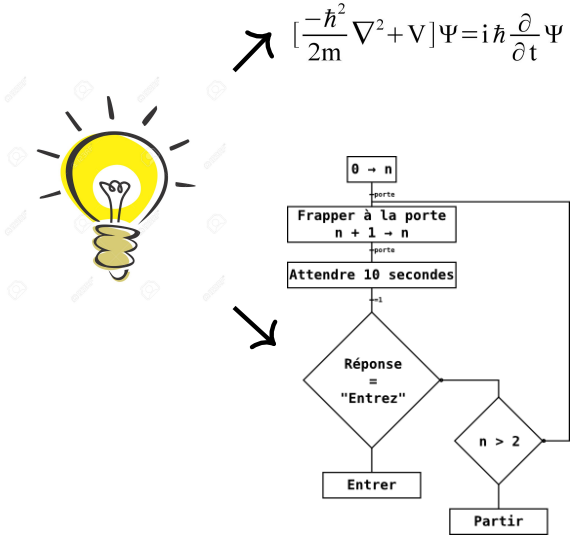

$$[\frac{-\hbar^2}{2m}\nabla^2+V]\Psi=i\hbar\frac{\partial}{\partial t}\Psi$$

Code → Traduction →

Comment peut-on être binaire ?

Spécialisation

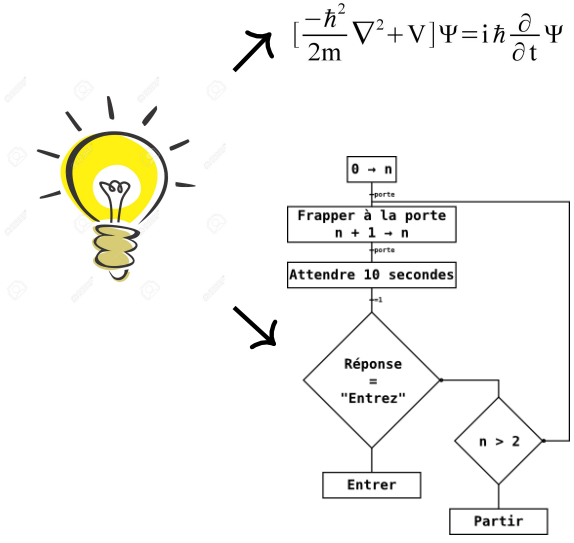

Code → Traduction

Reversing
Généralisation

Table of Contents

Un gradient d'approches

- Compilation : traduction statique en binaire
  - réutilisable
  - pour des inputs variés
  - adapté à un environnement particulier (windows, linux, osx,...)
  - ex: C, C++, Fortran

Un gradient d'approches

- Compilation : traduction statique en binaire
  - réutilisable
  - pour des inputs variés
  - adapté à un environnement particulier (windows, linux, osx,...)
  - ex: C, C++, Fortran

- Interprétation : traduction dynamique = à la volée
  - non-réutilisable
  - optimisée pour des inputs particuliers
  - ex: Basic, R, bash

Un gradient d'approches

- Compilation : traduction statique en binaire
  - réutilisable
  - pour des inputs variés
  - adapté à un environnement particulier (windows, linux, osx,...)
  - ex: C, C++, Fortran
- Pré-compilation : traduction statique vers un 'byte-code'
  - byte-code générique
  - adaptation à l'environnement au run-time
  - ex: Java

- Interprétation : traduction dynamique = à la volée
  - non-réutilisable
  - optimisée pour des inputs particuliers
  - ex: Basic, R, bash

Un gradient d'approches

- Compilation : traduction statique en binaire
  - réutilisable
  - pour des inputs variés
  - adapté à un environnement particulier (windows, linux, osx,...)
  - ex: C, C++, Fortran
- Pré-compilation : traduction statique vers un 'byte-code'
  - byte-code générique
  - adaptation à l'environnement au run-time
  - ex: Java
- JIT : Just-in-Time compilation
  - traduction dynamique partiellement 'réutilisable'
  - parfois limitée aux hot spots
  - ex: Matlab, Julia, Java
- Interprétation : traduction dynamique = à la volée
  - non-réutilisable
  - optimisée pour des inputs particuliers
  - ex: Basic, R, bash

Compilateurs C/C++

Compilateurs commerciaux

- Intel C/C++ compiler (icc) (Windows, linux, MacOs, Intel)
- Visual Studio C++ (Windows, Microsoft)
- IAR C/C++ compiler (Windows, Linux, others, IAR Systems)
- Edison Design Group (Windows, Linux, others, EDG)
- VisualAge C++, XL C/C++ (Windows, LInux, Aix, OS/2, OS/400,... IBM)
- ...

OpenSource ou Freeware

- GNU C/C++ (**gcc**, MinGW) (Windows, linux, MacOS, GNU Project)
- Clang/LLVM (**clang**) (Windows, linux, MacOS, LLVM Project)
- ...

https://en.wikipedia.org/wiki/List_of_compilers

Table of Contents

Une traduction en plusieurs étapes

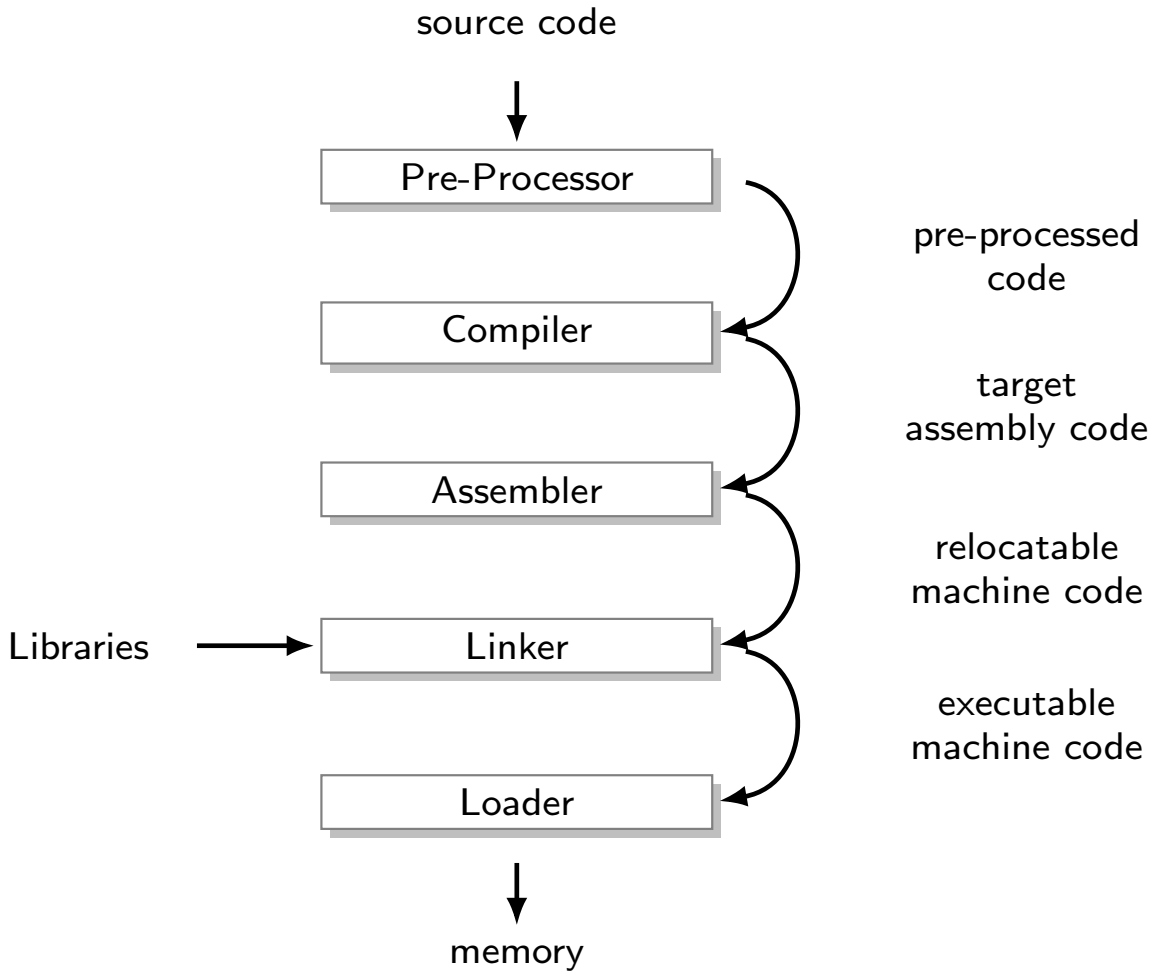

Une traduction en plusieurs étapes

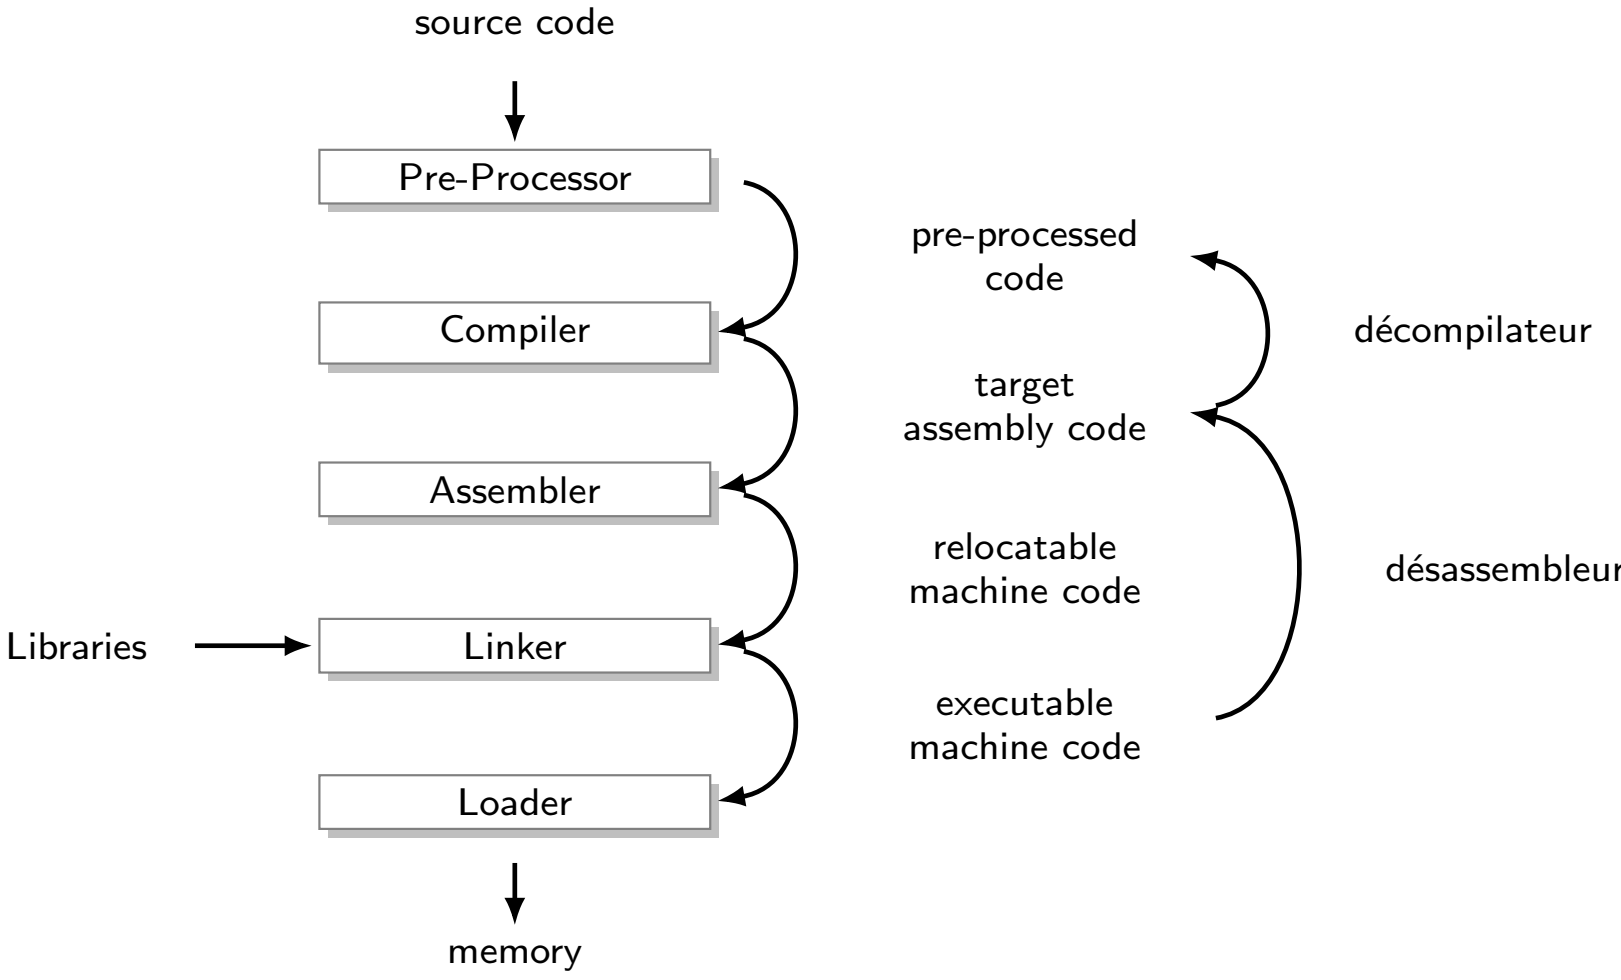

Une traduction en plusieurs étapes

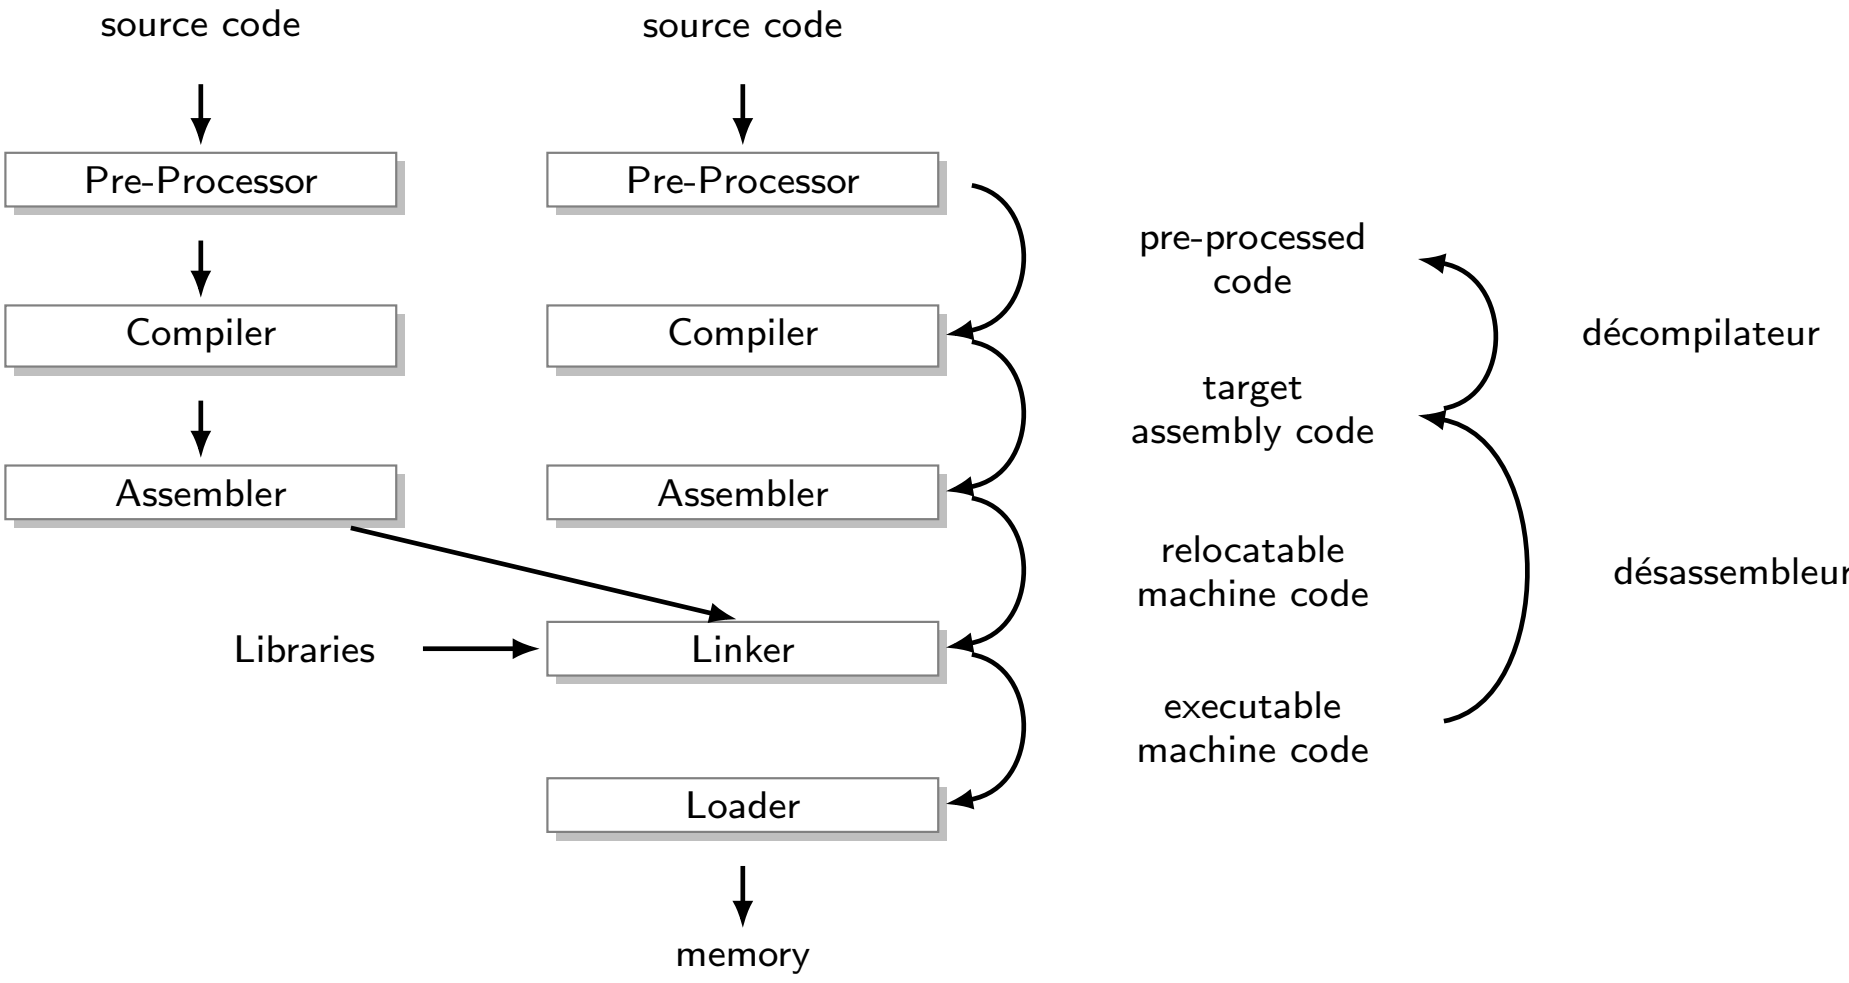

TD 1 : les étapes de la génération de binaire

`welcome.c` :

```c
#include <stdio.h>
void welcome(char const* nom) {
  printf("welcome %s!\n", nom);
}
```

`main_welcome.c` :

```c
#ifndef DEFAULT
#define DEFAULT "everybody"
#endif

extern void welcome(char const*);

int main(int argc, char const* argv[]) {
  if      (argc == 1) { welcome(DEFAULT); }
  else if (argc == 2) { welcome(argv[1]); }
  else { return 1; }
  return 0;
}
```

td1 : exécution

Version par défaut :

```
1  clang welcome.c main_welcome.c
2  ./a.out
3  ./a.out alice
```

td1 : exécution

Version par défaut :

```
clang welcome.c main_welcome.c
./a.out
./a.out alice
```

```
welcome everybody!
welcome alice!
```

td1 : exécution

Version par défaut :

```
1  clang welcome.c main_welcome.c
2  ./a.out
3  ./a.out alice
```

```
1  welcome everybody!
2  welcome alice!
```

Version avec définition de variable de pré-processing :

```
1  clang welcome.c main_welcome.c -DDEFAULT='"bob"'
2  ./a.out
3  ./a.out alice
```

td1 : exécution

Version par défaut :

```
1  clang welcome.c main_welcome.c
2  ./a.out
3  ./a.out alice
```

```
1  welcome everybody!
2  welcome alice!
```

Version avec définition de variable de pré-processing :

```
1  clang welcome.c main_welcome.c -DDEFAULT='"bob"'
2  ./a.out
3  ./a.out alice
```

```
1  welcome bob!
2  welcome alice!
```

Le pré-processeur : traitement des macros

```
1  clang -E main_welcome.c
```

Le pré-processeur : traitement des macros

```
clang -E main_welcome.c
```

```
int main(int argc, char const* argv[]) {
  if (argc == 1) { welcome("everybody"); }
  else if (argc == 2) { welcome(argv[1]); }
  else { return 1; }
  return 0;
}
```

Le pré-processeur : traitement des macros

```
clang -E main_welcome.c
```

```
int main(int argc, char const* argv[]) {
  if (argc == 1) { welcome("everybody"); }
  else if (argc == 2) { welcome(argv[1]); }
  else { return 1; }
  return 0;
}
```

```
clang -E main_welcome.c -DDEFAULT='"bob"'
```

Le pré-processeur : traitement des macros

```
clang -E main_welcome.c
```

```
int main(int argc, char const* argv[]) {
  if (argc == 1) { welcome("everybody"); }
  else if (argc == 2) { welcome(argv[1]); }
  else { return 1; }
  return 0;
}
```

```
clang -E main_welcome.c -DDEFAULT='"bob"'
```

```
int main(int argc, char const* argv[]) {
  if (argc == 1) { welcome("bob"); }
  else if (argc == 2) { welcome(argv[1]); }
  else { return 1; }
  return 0;
}
```

Le pré-processeur : inclusion de fichiers *header*

```
1  clang -E welcome.c | wc -l
```

```
1  797
```

Le pré-processeur : inclusion de fichiers *header*

```
1  clang -E welcome.c | wc -l
```

```
1  797
```

```
1  clang -E welcome.c
```

Le pré-processeur : inclusion de fichiers *header*

```
clang -E welcome.c | wc -l
```

```
797
```

```
clang -E welcome.c
```

- les fichiers sont intégralement inclus, récursivement
- attention aux include redondants

```
#ifndef MY_HEADER_H_
#define MY_HEADER_H_
.... // header content
#endif // MY_HEADER_H_
```

- attention à l'expansion de macros !

Le compilateur : génération de code assembleur

```
1  clang -S main_welcome.c
2  more main_welcome.s
```

L'assemblage: génération de code objet

```
1  as main_welcome.s -o main_welcome.o
2  file main_welcome.o
3  nm main_welcome.o
```

L'assemblage: génération de code objet

```
1  as main_welcome.s -o main_welcome.o
2  file main_welcome.o
3  nm main_welcome.o
```

```
1  main_welcome.o: ELF 64-bit LSB relocatable, x86-64, version 1 (
       SYSV), not stripped
2
3                  U _GLOBAL_OFFSET_TABLE_
4  0000000000000000 T main
5                  U welcome
```

L'assemblage: génération de code objet

```
1  as main_welcome.s -o main_welcome.o
2  file main_welcome.o
3  nm main_welcome.o
```

```
1  main_welcome.o: ELF 64-bit LSB relocatable, x86-64, version 1 (
       SYSV), not stripped
2
3                  U _GLOBAL_OFFSET_TABLE_
4  0000000000000000 T main
5                  U welcome
```

```
1  clang -c welcome.c -o welcome.o
2  file welcome.o
3  nm welcome.o
```

L'assemblage: génération de code objet

```
as main_welcome.s -o main_welcome.o
file main_welcome.o
nm main_welcome.o
```

```
main_welcome.o: ELF 64-bit LSB relocatable, x86-64, version 1 (SYSV), not stripped

                 U _GLOBAL_OFFSET_TABLE_
0000000000000000 T main
                 U welcome
```

```
clang -c welcome.c -o welcome.o
file welcome.o
nm welcome.o
```

```
welcome.o: ELF 64-bit LSB relocatable, x86-64, version 1 (SYSV), not stripped

                 U _GLOBAL_OFFSET_TABLE_
                 U printf
0000000000000000 T welcome
```

L'édition de lien: génération de binaire

```
1  ld welcome.o main_welcome.o
```

L'édition de lien: génération de binaire

```
1  ld welcome.o main_welcome.o
```

```
1  ld : avertissement: le symbole d'entree _start est introuvable
       ; utilise par defaut 00000000004000b0
2  welcome.o: Dans la fonction « welcome » :
3  welcome.c:(.text+0x20) : reference indefinie vers « printf »
```

L'édition de lien: génération de binaire

```
1  ld welcome.o main_welcome.o
```

```
1  ld : avertissement: le symbole d'entree _start est introuvable
       ; utilise par defaut 00000000004000b0
2  welcome.o: Dans la fonction « welcome » :
3  welcome.c:(.text+0x20) : reference indefinie vers « printf »
```

```
1  ld welcome.o main_welcome.o -lc
2  file a.out
```

L'édition de lien: génération de binaire

```
1  ld welcome.o main_welcome.o
```

```
1  ld : avertissement: le symbole d'entree _start est introuvable
       ; utilise par defaut 00000000004000b0
2  welcome.o: Dans la fonction « welcome » :
3  welcome.c:(.text+0x20) : reference indefinie vers « printf »
```

```
1  ld welcome.o main_welcome.o -lc
2  file a.out
```

```
1
2  ld:  avertissement: le symbole d'entree _start est  introuvable;
        utilise par defaut 00000000004002c0
3
4  a.out: ELF 64-bit LSB executable, x86-64, version 1 (SYSV),
       dynamically linked, interpreter /lib/ld64.so.1, not
       stripped
```

L'édition de lien: génération de binaire

```
1  clang -v welcome.o main_welcome.o 2>&1 | grep ld
```

L'édition de lien: génération de binaire

```
clang -v welcome.o main_welcome.o 2>&1 | grep ld
```

```
"/usr/bin/ld" -z relro --hash-style=gnu --eh-frame-hdr -m
    elf_x86_64 -dynamic-linker /lib64/ld-linux-x86-64.so.2 -o
    a.out /usr/bin/../lib/gcc/x86_64-linux-gnu/7.3.0/../../../
    x86_64-linux-gnu/crt1.o /usr/bin/../lib/gcc/x86_64-linux-
    gnu/7.3.0/../../../x86_64-linux-gnu/crti.o /usr/bin/../lib
    /gcc/x86_64-linux-gnu/7.3.0/crtbegin.o -L/usr/bin/../lib/
    gcc/x86_64-linux-gnu/7.3.0 -L/usr/bin/../lib/gcc/x86_64-
    linux-gnu/7.3.0/../../../x86_64-linux-gnu -L/lib/x86_64-
    linux-gnu -L/lib/../lib64 -L/usr/lib/x86_64-linux-gnu -L/
    usr/bin/../lib/gcc/x86_64-linux-gnu/7.3.0/../../.. -L/usr/
    lib/llvm-6.0/bin/../lib -L/lib -L/usr/lib welcome.o
    main_welcome.o -lgcc --as-needed -lgcc_s --no-as-needed -
    lc -lgcc --as-needed -lgcc_s --no-as-needed /usr/bin/../
    lib/gcc/x86_64-linux-gnu/7.3.0/crtend.o /usr/bin/../lib/
    gcc/x86_64-linux-gnu/7.3.0/../../../x86_64-linux-gnu/crtn.
    o
```

Table of Contents

Piloter son compilateur : les options

Contrôle des inputs/outputs

- fichiers sources : paramètres positionnels
- bibliothèques : `-l<libname>`
- chemins d'accès
  - fichiers headers : `-I<path>`
  - bibliothèques : `-L<path>`
- standard du language : `-std=c++11` par ex.
- warnings : `-W<warning>` (ex: `-Wall`, `-Werror`)
- infos : `--help`, `--version`, `-print-search-dirs`, `...`

Passer des options aux différentes étapes

- pré-processeur: `-Wp,<option>`
- assembleur: `-Wa,<option>`
- linker: `-Wl,<option>`

Piloter l'optimiseur

Liste des optimisations :

- gcc/g++:

```
1           g++ --help=optimizers
```

- clang/llvm:

```
1           clang -help
2           opt -help
```

Optimisations globales : `-O<level>`

- `-O0` : pas d'optimisations, pratique pour le debug
- `-O3` : plus fort niveau d'optimisations
- `-Os` : `-O2`, mais minimise la taille du code
- `-Ofast`: `-O3` + `-ffastmath`

TD 2 : Piloter l'optimiseur

```
1  #ifdef BIG_N
2  #define n 100
3  #else
4  #define n 5
5  #endif
6
7  int main() {
8    int a[n];
9    for (int i = 0; i < n; ++i) { a[i] = i+1; }
10
11   int s = 0;
12   for (int i = 0; i < n; ++i) { s +=a [i]; }
13
14   if ( s== (n*(n+1))/2 )       { return s; }
15   return -1;
16 }
```

- avec *#define n 5*
  Comparer les assembleurs générés avec `-O0` et `-O2`
- avec *#define n 100*
  Comparer les binaires générés avec `-O0` et `-O3`

TD 3 : les options pour le debug (1)

```c
#include <assert.h>
#define MAX_SIZE 512

int count_char(const char* str) {
  int c = 0;
  while ( (c < MAX_SIZE) && (str[c] != '\0')) { ++c; }
  return c;
}

int main(int argc, char** argv) {
  assert(argc == 2 && "compliant number of arguments");
  return count_char(argv[1]);
}
```

```
clang debug.c -o debug
./debug toto
echo $?
./debug
```

TD 3 : les options pour le debug (2)

L'impact de `-DNDEBUG`

```
1  clang debug.c -o debug-n -DNDEBUG
2  ./debug-n toto
3  echo $?
4  ./debug-n
```

Comparer les binaires générés avec et sans `-DNDEBUG`

L'impact de `-g`

```
1  clang debug.c -o debug-ng -DNDEBUG -g
```

Comparer les binaires générés avec et sans `-g`

Table of Contents

TD 4 : clang vs. gcc

Reprendre le programme `array.c` du TD 2

Comparer les assembleurs générés par gcc et clang pour `n = 100` et différents niveaux d'option `-O<level>` :

`td4/gcc_vs_clang.sh` :

```
1  LEVEL=$1
2
3  # assembleur
4  clang array.c -DBIG_N -O$LEVEL -S -o array_clang_O$LEVEL.s
5  gcc array.c -DBIG_N -O$LEVEL -S -o array_gcc_O$LEVEL.s
6
7  # binaire
8  clang array.c -DBIG_N -O$LEVEL -o array_clang_O$LEVEL
9  gcc array.c -DBIG_N -O$LEVEL -o array_gcc_O$LEVEL
```

```
1  bash gcc_vs_clang.sh 1
2  bash gcc_vs_clang.sh 2
3  bash gcc_vs_clang.sh 3
```

Comparer aussi les versions générées par clang avec `-O2` et gcc avec `-O3`.

Jouer avec les compilateurs

https://godbolt.org/

Outil permettant de visionner les assembleurs générés par différents compilateurs pour différentes platformes (x86_64, armxx,...)
(développé par Matt Godbolt)

https://cppinsights.io/

Outil basé sur Clang, qui permet de voir comment le front-end transforme le code
(développé par Andreas Fertig)

Table of Contents

Clang/LLVM

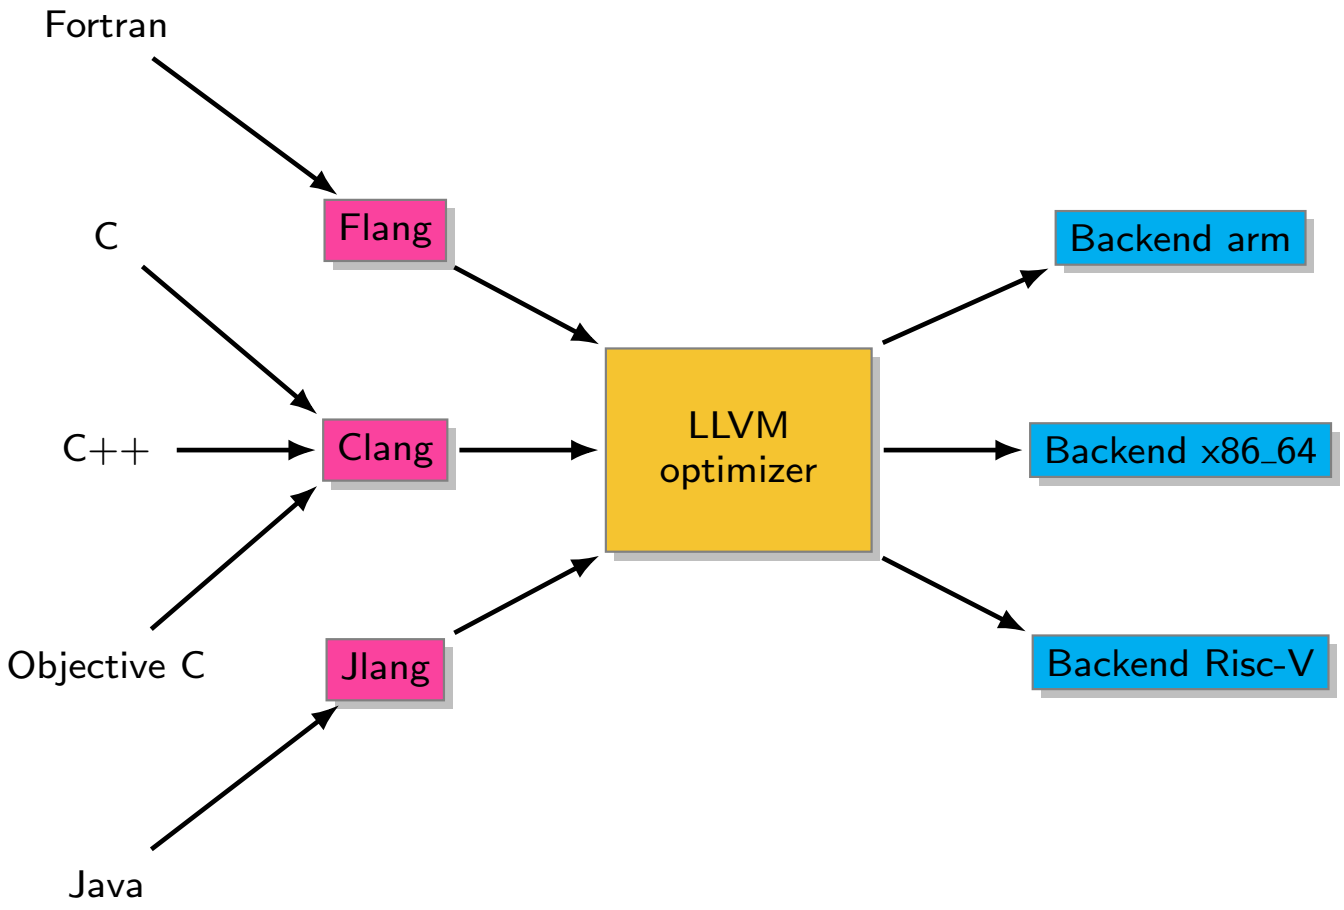
Fortran
C
C++
Objective C
Java
Flang
Clang
Jlang
LLVM
optimizer
Backend arm
Backend x86_64
Backend Risc-V

LLVM : organisation en passes

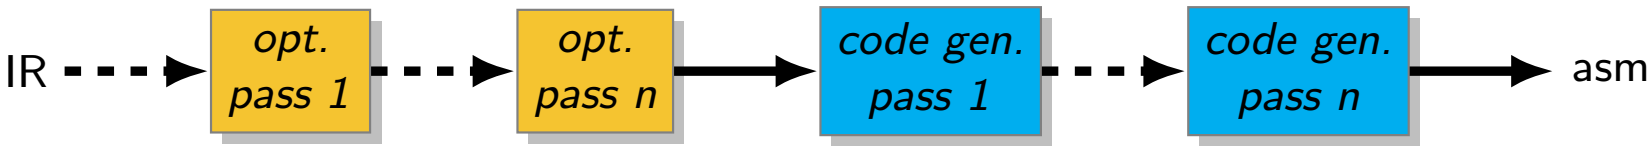

LLVM : organisation en passes

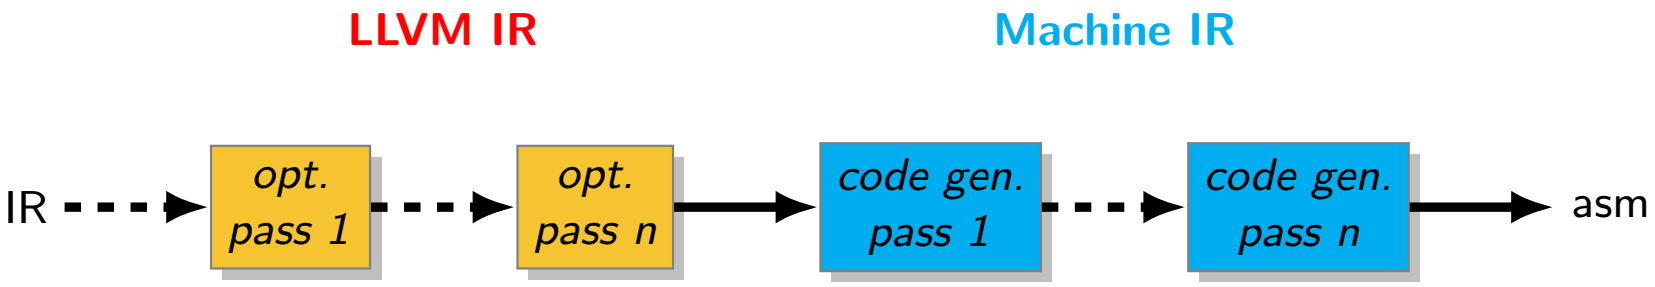

LLVM : organisation en passes

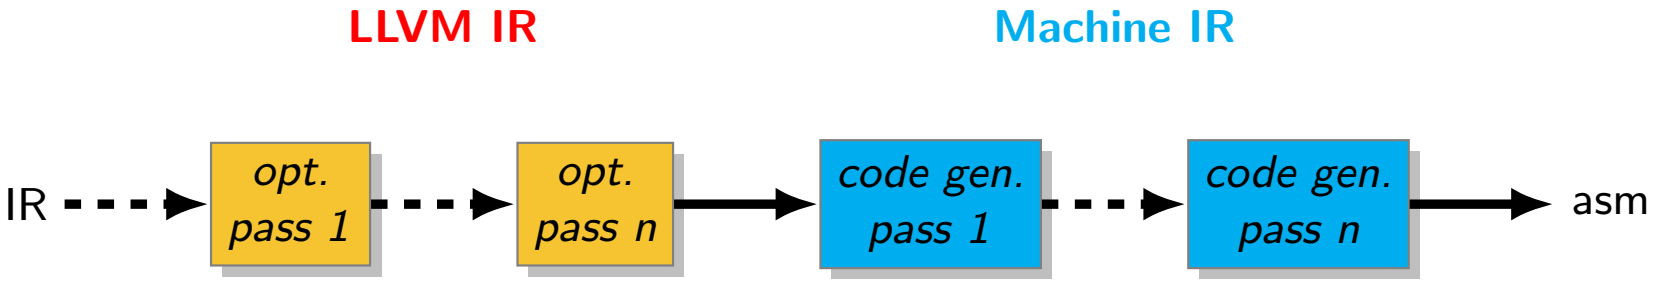

Inlining, Outlining, Cloning
Function Merging
Global Dead Code elimination
Constant Propagation
Constant Folding
Common Subexpressions Elimination
Dead Code Elimination
Loop Invariant Code Motion
Loop Unrolling
Vectorizer
...

LLVM : organisation en passes

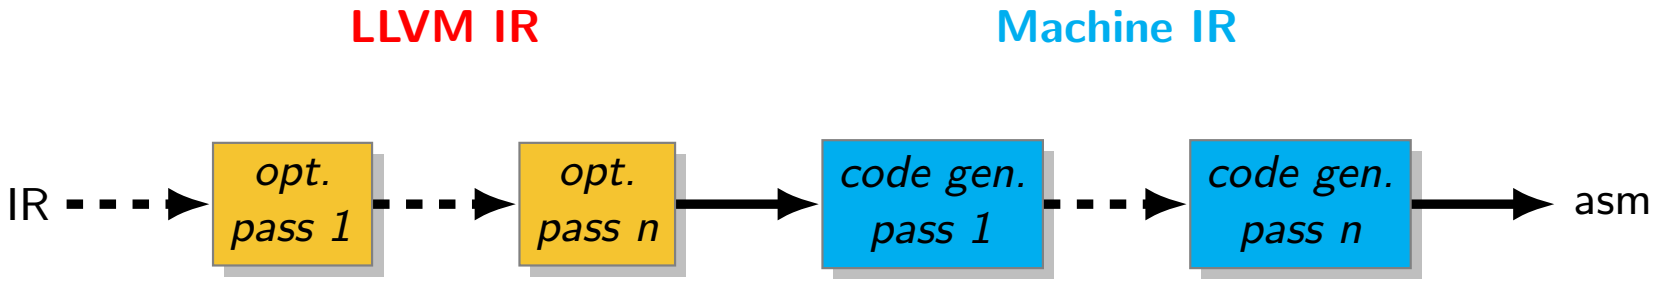

Inlining, Outlining, Cloning
Function Merging
Global Dead Code elimination
Constant Propagation
Constant Folding
Common Subexpressions Elimination
Dead Code Elimination
Loop Invariant Code Motion
Loop Unrolling
Vectorizer
...

Register Allocation
ISel
Peephole Optimizer
Target Lowering
...

https://llvm.org/docs/Passes.html
https://github.com/llvm-mirror/llvm/blob/master/lib/Transforms/IPO/PassManagerBuilder.cpp

Transformations interprocédurales

- Inlining, outlining, merge de fonctions, cloning, global dce,. . .
- sur le Call Graph
- sur les variables globales

Transformations intraprocédurales

- Constant propagation, Common subexpressions elimination, loop transformations, ...
- nécessite de pouvoir déplacer les instructions les unes par rapport aux autres
- en respectant leurs dépendances :
  - **spatiales**
    (est-ce que je touche la même zone mémoire ou le même registre?)
  - **temporelles**
    (est-ce que ce store est exécuté avant de load?)

LLVM apporte ces informations sous différentes formes:

- sa représentation interne (la LLVM IR)
  - Basic blocks et CFG
  - forme SSA
    transforme les dépendances de registres en chaînes de valeurs (use-defs chains)
    attention : ne prend pas en compte les dépendances de mémoire
- des analyses que les passes de transformation peuvent requérir
  - AliasAnalysis (AA)
  - MemorySSA
  - ...

Table of Contents

Désassembleur/Décompileur = Compilateur ?

- Concepts communs (transformer du code, RI)
- Outils communs
  - CFG, CG
  - Analyses de flot de valeurs, forme SSA

Utiliser une RI commune (par exemple la LLVM IR) ?

- RetDec, McSema/ReMill
- Pour capitaliser l'existant
- Pour bénéficier d'outils d'analyse / transformation externes
  - ex: Klee, Souper
  - cf. Saturn (SPro'19)
- Pas forcément toujours souhaitable / possible
  - avoir une IR multi-level (= MLIR ;p)

Obfusquer = Transformer = Compiler

Obfusquer = Complexifier mais Compiler = Optimiser

Obfusquer = Transformer = Compiler

Obfusquer = Complexifier mais Compiler = Optimiser

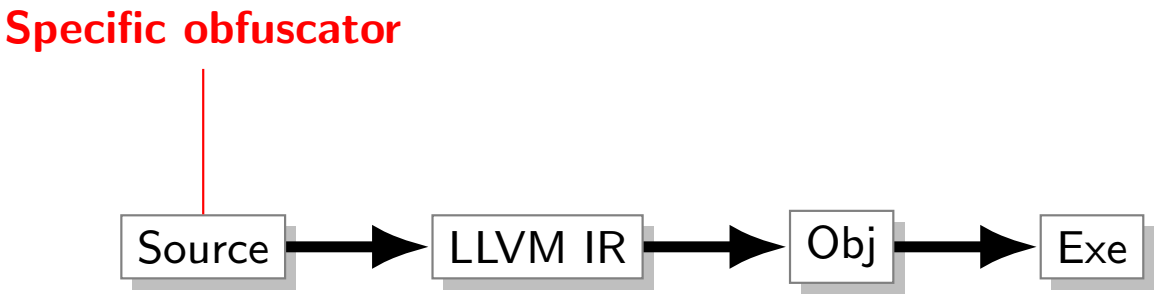

Obfusquer = Transformer = Compiler

Obfusquer = Complexifier mais Compiler = Optimiser

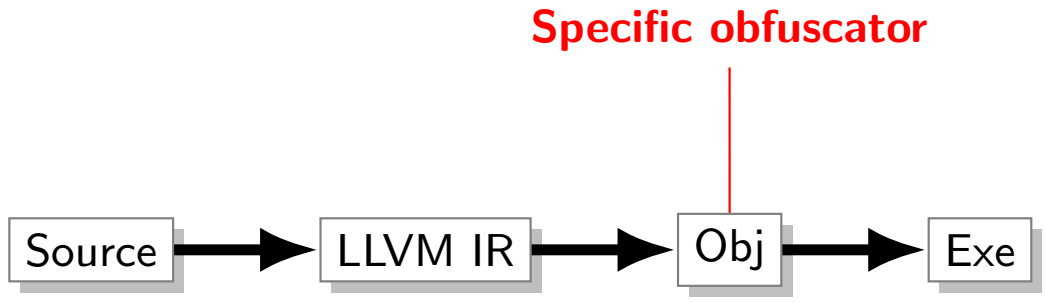

Obfusquer = Transformer = Compiler

Obfusquer = Complexifier mais Compiler = Optimiser

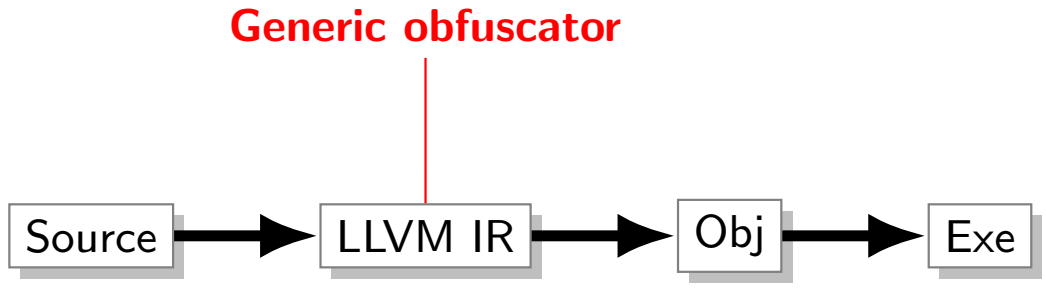

Obfusquer = Transformer = Compiler

Obfusquer = Complexifier mais Compiler = Optimiser

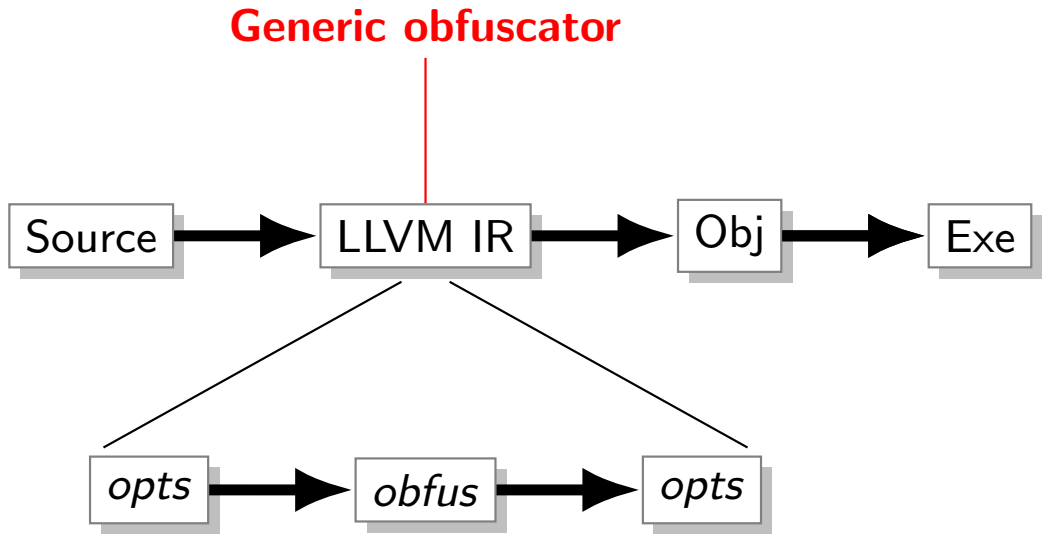

Table of Contents